训练数据画错了，AI 还能用吗？

我用公开的脑部 MRI 数据做了一个小实验，回答三个问题：训练用的标注出错，会让模型差多少？
能不能让程序自动把错的挑出来？把模型压缩到小设备也能跑，要付出什么代价？

先说结论

- 就算 40% 的标注被故意画错，模型的准确度也只掉了约 0.5 个百分点。
- 自动检查能抓出大部分画错的，但把它们删掉再训练，模型没有变好。
- 压缩之后，小模型准确度没变，文件小 3.7 倍，处理速度快 2.2 倍。大模型快 2.9 倍，但准确度掉了 1.3 个百分点。

故意画错一部分标注
三种常见的错法
0 / 20 / 40%

训练模型
2 种小模型，各训练 3 次
共 30 次

自动检查标注
把可疑的挑出来删掉
抓到 53 / 64

删掉后再训练一次
看有没有变好
没有变好

压缩模型
比较大小和速度
小 3.7 倍

真实项目里，标注总会有错，而且模型最后要装进算力很小的设备。

一个医学影像项目的日常

- AI 要学会在 MRI 里把某个器官圈出来，老师是医生手工画的轮廓，这叫标注。
- 人画多了就会出错：画大了、画歪了、手滑多画了一块。
- 训练好的模型还要装进算力有限的设备里，得先压缩。

所以我想知道

- 标注错一部分，模型会差多少？
- 有没有办法自动挑出画错的？挑出来删掉有用吗？
- 压缩模型，准确度和速度各变多少？

我把这三件事放在同一条流水线上，一次测完。

用公开数据，故意把标注画错，再看后果。

四步

- **造脏数据。**用公开的海马体 MRI 数据（260 个病例），把其中 20% 或 40% 的标注故意画错：画大或画小、整体偏移、多画一块。
- **训练。**用脏数据训练两种小模型，每种、每个比例都训练 3 次，一共 30 次。
- **自动检查。**用一个已有的检查程序给每个标注打分，把最可疑的那部分删掉，再训练一遍。
- **压缩。**把模型压成更小的数字格式，在普通 CPU 上比较大小和速度。

怎么打分

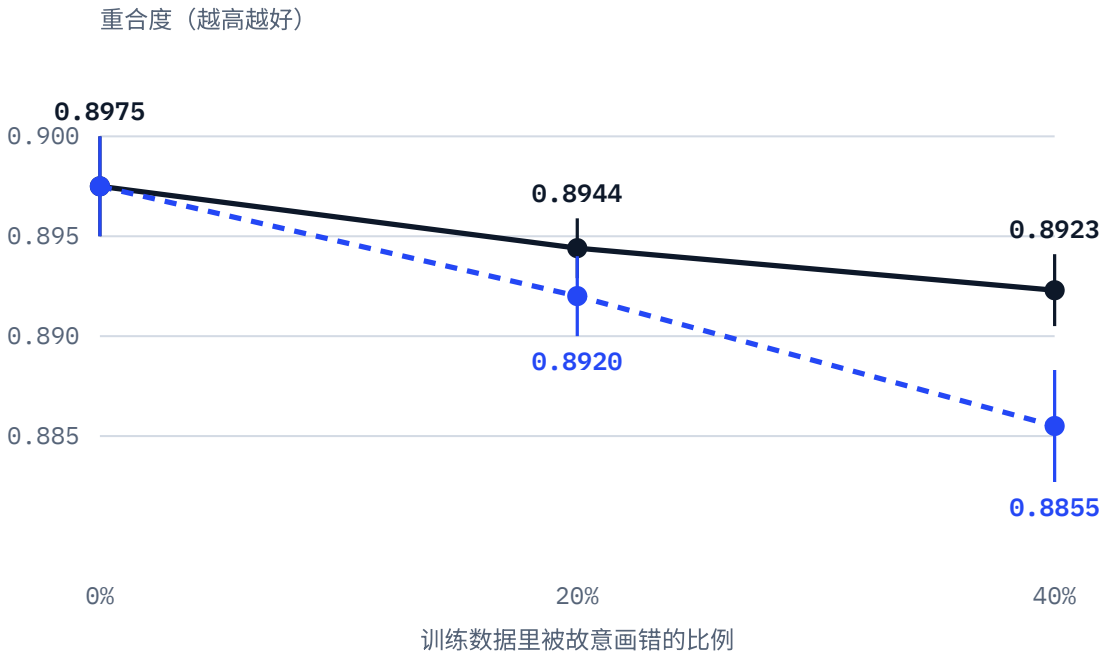
用“重合度”：模型画出的轮廓和医生画的轮廓重合多少。1 表示完全一样。本项目里的模型大约在 0.89，也就是约 89% 重合。

怎么保证公平

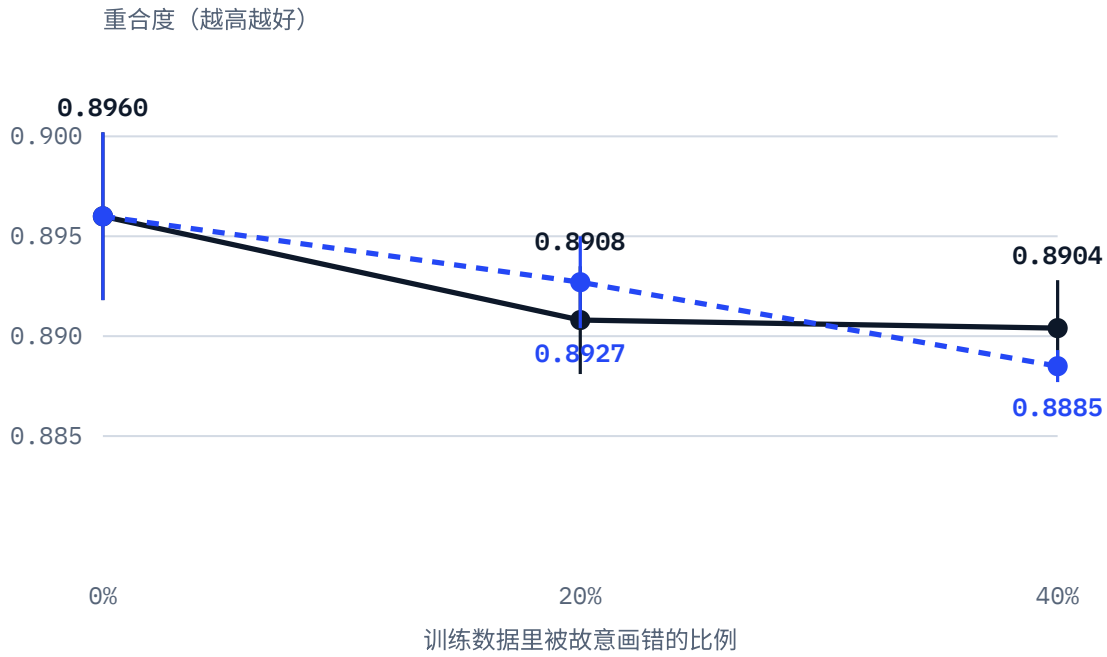
- 测试用的 60 个病例从不参与训练，标注始终是对的。
- 按病例分开，同一个人的图不会同时出现在训练和测试里。
- 跑之前先写下 7 条预测，结果不好看也照实写。

标注画错 40%，模型只差了约半个百分点。

从零训练的小模型



用预训练编码器的模型

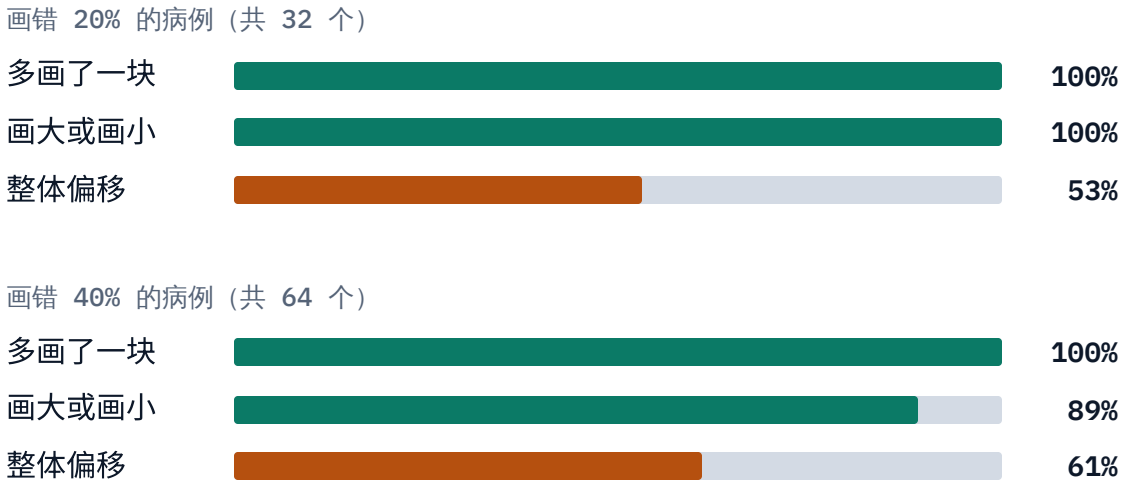


不处理　自动删掉可疑标注后　每种情况训练 3 次取平均，竖线是 3 次之间的波动

小模型的重合度从 0.8975 降到 0.8923，另一个模型也只降了 0.0056。这点差别和重复训练的随机波动差不多大。**这个程度的标注错误，对这个任务影响不大。**

自动检查能抓出大部分画错的，但删掉它们，模型没有变好。

画错的标注，被抓到了多少



合计：画错 20% 时抓到 24 / 32，画错 40% 时抓到 53 / 64。整体偏移的最难发现。

删掉可疑标注后再训练，结果怎么样

- 小模型：反而差了一点（少 0.0024 和 0.0068）。
- 另一个模型：一次好一点（多 0.0019），一次差一点（少 0.0019）。

> **为什么没用：**删掉 20% 到 40% 的病例，模型就少学了这么多数据，损失和标注画错造成的损失差不多大。而且这个噪声本来就没造成多大伤害，没有多少可挽回的。

压缩后，小模型一点没变差；大模型快了很多，但准确度掉了一点。

从零训练的小模型

准确度（重合度）	0.8952 → 0.8952	几乎没变
模型文件大小	1.93 → 0.53 MB	小 3.7 倍
处理一张图的时间	2.58 → 1.18 ms	快 2.2 倍



压缩前后，准确度到小数点后四位都一样。

用预训练编码器的大模型

准确度（重合度）	0.8912 → 0.8779	下降 0.0133
模型文件大小	57.28 → 14.47 MB	小 4.0 倍
处理一张图的时间	6.07 → 2.10 ms	快 2.9 倍



体积和速度的收益更大，准确度掉了约 1.3 个百分点。

> 大模型掉的这 1.3 个百分点，上线前要查清原因。可以试更好的校准数据，或者在压缩时一起训练。这两种这次都没有试。

测速环境：4 核云端 CPU，单线程，每次处理 1 张图，共 1501 张测试图。这不是真正的嵌入式设备，也不是笔记本。

电脑画的假图能帮上忙吗？只能算勉强有一点。

在真实的测试病例上，准确度（重合度）是多少

只用 20 个真实病例



0.8568 ± 0.0062

先用电脑合成的假图预热，再学同样的 20 个真实病例



0.8673 ± 0.0059

只用假图，一个真实病例都不给



0.3429 ± 0.0094

怎么理解

我让电脑生成了 500 个“假脑”：随机朝向、大小、明暗的椭球体，每个都自带完美标注。

只用假图几乎学不会，因为假图比真实 MRI 清楚得多：目标和背景的反差是 **2.41**，真实图只有 **0.55**。

> 先用假图预热、再学 20 个真实病例，平均比只学真实病例好 0.0105。但 3 次里只有 2 次更好，所以只能算“可能有一点用”。

跑之前写下 7 条预测：2 条对，2 条错，3 条部分对。

#	我当时预测	实际结果
1	标注画错 40%，模型会变差	对 确实变差了，但只差 0.0052 和 0.0056
2	预训练的模型更抗标注错误	错 没有更抗：0.0056 对 0.0052
3	删掉可疑标注能找回一部分损失，而且会漏掉不少	错 没有找回；40% 时抓到了 83%，比我预想的高
4	压缩后准确度掉得不到 0.01	部分对 小模型没掉，大模型掉了 0.0133
5	文件小 3 到 4 倍，速度提升不确定	部分对 体积对；两个模型都变快了，我原以为小模型不会变快
6	只用假图，明显不如只用真图	对 0.3429 对 0.8568
7	假图预热再学真图，比只学真图好	部分对 平均好 0.0105，但 3 次里只有 2 次

这个实验的局限：只用了一个小型公开数据集，图很小（约 50×35 像素），不做任何临床结论。标注错误是我人为制造的，不一定像真实医生之间的分歧。只切分了一次数据。压缩的测试每种模型只用了 1 个，且在云端 CPU 上测，没有做嵌入式设备测试。